

# **Interfaces para el Control de Sistemas Robóticos Utilizando Combinaciones de Señales Biomédicas**

## **Interfaces for the Control of Robotic Systems Using Combinations of Biomedical Signals**

Roberto José Cáceres García (cac17163@uvg.edu.gt)

Departamento de Ingeniería Electrónica, Mecatrónica y Biomédica, Facultad de Ingeniería, Universidad Del Valle de Guatemala

### **Resumen**

El estudio de las señales electromiográficas y electroencefalográficas de superficie, son fundamentales en el desarrollo de aplicaciones de dispositivos de asistencia médica, como prótesis robóticas utilizando interfaces humano-computadora. La mayoría de éstas prótesis funcionan utilizando señales electromiográficas de superficie, utilizando los músculos residuales de los miembros amputados. Como se pierde funcionalidad muscular, lo que limita el uso de las señales para poder utilizarlo en algoritmos de clasificación de inteligencia artificial, ya que las señales al ser débiles dejan de ser tan discriminantes entre sí. Este trabajo se propone la investigación de dos enfoques para la combinación de señales, el primero es utilizar las señales EEG como una señal auxiliar para mejorar el rendimiento en los algoritmos de inteligencia artificial utilizando solo gestos musculares. El segundo enfoque fue utilizar la combinación de señales, aumentando el número de clases en la clasificación, realizando más gestos y así poder cumplir con las demandas de grados de libertad de las prótesis robóticas. Se diseñaron 3 interfaces recolectoras de datos por cada señal: EMG, EEG y EEG-EMG, así como otras 3 interfaces para la clasificación y prueba de entrenamientos, enviando comandos al robot R17 de la Universidad del Valle de Guatemala. Para señales EMG se logró un rendimiento del 89.9% utilizando máquina de soporte de vectores. Para señales EEG se logró un 89.4% de rendimiento utilizando máquina de soporte de vectores. En el primer enfoque de la combinación de señales se logró un 92.4% de rendimiento utilizando regresión logística. En el segundo enfoque de la combinación de señales se logró un 89.5% de rendimiento utilizando máquina de soporte de vectores.

**Palabras clave:** clases, características, entrenamientos, paradigma, electro cap, bitalino, rendimiento, HMI, R17, combinación de señales.

## **Abstract**

The study of surface electromyographic and electroencephalographic signals are fundamental in the development of applications for medical assistance devices, such as robotic prostheses using human-computer interfaces. Most of these prostheses work using surface electromyographic signals, using the residual muscles of the amputated limbs. As muscular functionality is lost, which limits the use of the signals to be able to use it in artificial intelligence classification algorithms, since the signals, being weak, are no longer so discriminating among themselves. This work proposes the investigation of two approaches to signal combination, the first is to use EEG signals as an auxiliary signal to improve accuracy in artificial intelligence algorithms using only muscle gestures. The second approach was to use the combination of signals, increasing the number of classes in the classification, making more gestures and thus being able to meet the demands of degrees of freedom of robotic prostheses. 3 data collection interfaces were designed for each signal: EMG, EEG and EEG-EMG, as well as 3 other interfaces for classifying and testing training, sending commands to the R17 robot of the Universidad del Valle de Guatemala. For EMG signals, a yield of 89.9% was achieved using vector support machine. For EEG signals, 89.4% yield was achieved using vector support machine. In the first approach of the combination of signals, a 92.4% yield was achieved using logistic regression. In the second approach to signal combination, 89.5% performance was achieved using vector support machine.

**Keywords:** classes, features, trainings, paradigm, electro cap, bitalino, accuracy, HMI, R17.

## **Introducción**

El estudio de las señales biomédicas ha logrado numerosos aportes a la ciencia en general, logrando una diversidad de dispositivos de asistencia médica, con el fin de mejorar el bienestar físico de personas que padecen de discapacidades motrices. Así como acercamientos a poder utilizar chips cerebrales con fines de controlar enfermedades neurológicas. Las señales tanto electromiográficas como electroencefalográficas de superficie juegan un papel importante de los estudios para poder realizar todos estos avances. Esto es una forma segura, ya que se realizan de forma no invasiva.

Actualmente existen diversos dispositivos para poder capturar las señales biomédicas, permitiendo el desarrollo en la investigación y experimentación con las señales. La captura de estas señales permite el poder utilizarlas como señales traducidas en comandos para sistemas robóticos. Por lo que un requisito obvio para la implementación de este paradigma experimental es que el individuo en cuestión sea capaz de generar de forma intencional estas señales. Luego de cumplir con este requisito es importante el desarrollo

de una interfaz humano-computadora o HMI como se le conoce por sus siglas en inglés (Human-Machine interfaces) que sea capaz de procesar estas señales y designar el comando que mejor se adapte a la señal enviada por el individuo. Esto implica que al existir individuos que tengan un miembro superior amputado, pierdan la capacidad de generar de forma intencional estas señales en sus músculos para ser utilizadas en una HMI. Este tipo de pacientes pueden presentar el síndrome del miembro fantasma de acuerdo con Ebensperger y Méndez (2018), el cual debido al atrapamiento de los nervios seccionados por otras estructuras cicatrízales, los cuales estimulan a las estructuras superiores, que al no existir una coexistencia anatómica causa dolor. Esto implica pérdida en la función muscular de estas partes del cuerpo, donde seguramente se podría colocar una prótesis. Por lo que en este trabajo se considera el estudio de la combinación de señales electromiográficas y electroencefalográficas, para poder traducir esta combinación de señales en comandos que la HMI pueda interpretar y así incentivar el desarrollo de dispositivos de asistencia médica que tomen en cuenta la combinación de señales como una alternativa a solo utilizar una señal que demanda más procesamiento al ser menos discriminante por las pérdidas de su función muscular. En las aplicaciones reales, los músculos residuales (músculos que quedan después de la amputación) suelen ser limitados, especialmente en el caso de las amputaciones por encima del codo como mencionan Xiangxin y colaboradores (2017).

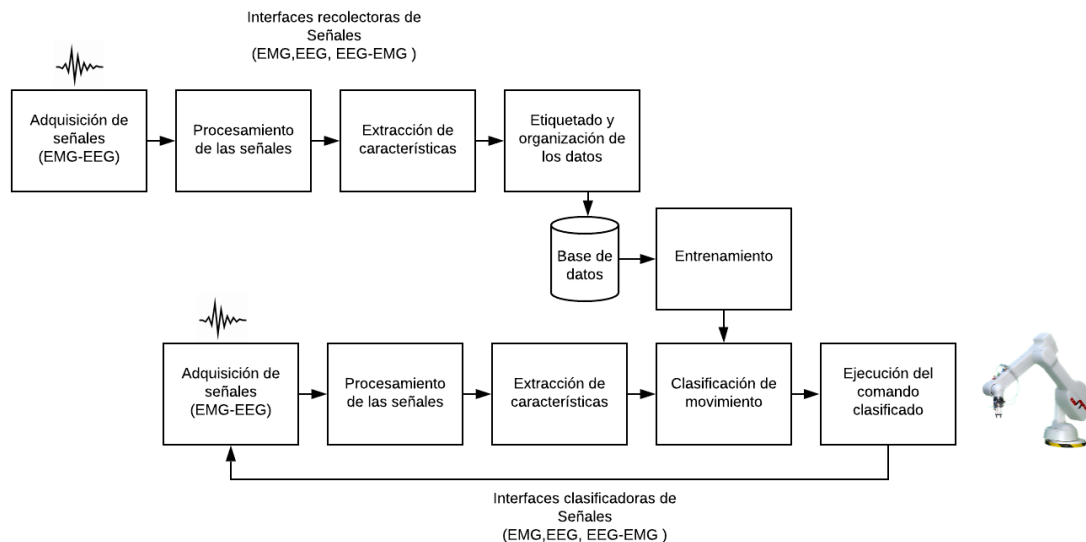
Hay otras investigaciones que se enfocan en combinar las señales electroencefalográficas y electromiográficas, pero más enfocado en combinar las señales para clases distintas y no en funcionar como una señal auxiliar a una señal electromiográfica que no son útiles como entradas. Como realizan Dulantha y colaboradores (2013), donde se enfocan en realizar paradigmas experimentales por ejemplo para una persona que tiene completamente paralizada una extremidad superior totalmente paralizada, por lo que estas personas no pueden hacer uso de un exoesqueleto debido a la dificultad de obtener señales de control de los músculos de la extremidad paralizada.

En este trabajo con los dispositivos de captura de señales con los que cuenta la Universidad del Valle de Guatemala, se desarrolló un método híbrido no invasivo, que combina las señales electromiográficas y electroencefalográficas, de forma paralela para poder clasificar los movimientos de extremidades superiores utilizando esta combinación de señales. también se desarrolló un método no invasivo para poder trabajar con ambas señales por separado y hacer estudios independientes. Por esto la investigación llevo a concretar el desarrollo de 6 interfaces humano-computadora tomando como base los trabajos de Girón (2020) y Ralda (2020), que desarrollaron las fases previas en esta línea de investigación de la Universidad del Valle de Guatemala. Cada interfaz cuenta con las etapas de adquisición y procesamiento de señales y un algoritmo de identificación de actividad. Las primeras 3 interfaces sirven para la recolección de datos en el orden específico de señales EMG; EEG; EEG-EMG. Al obtener las señales prosigue una etapa de extracción de

características, para poder utilizar éstas como vectores de características en entrenamientos con algoritmos de clasificación de inteligencia artificial. Las otras 3 interfaces desarrolladas fueron las interfaces clasificadoras, las cuales también cuentan con las etapas de adquisición y procesamiento de señales y un algoritmo de identificación de actividad, pero utilizando los modelos previamente entrenados, para clasificar las señales y poder enviarle comandos a un sistema robótico, en este caso el Robot R17 con el que cuenta la universidad.

## Materiales y métodos

En la figura 1 se puede observar la estructura de funcionamiento del sistema de las interfaces biomédicas. Como se puede observar se describen las etapas de cada una de las interfaces en general. Para cada interfaz se tiene una etapa de adquisición de señales, una etapa de procesamiento de las señales (entiéndase filtrados y conversiones de las señales), una etapa de extracción de características. En el caso de las interfaces recolectoras una etapa de etiquetado y organización de los datos, así como una etapa de entrenamiento de clasificadores. En el caso de las interfaces clasificadoras se le agrega la etapa de clasificación de movimiento y la etapa del envío del comando al robot R17. Estas interfaces fueron desarrolladas en la herramienta de *software* MATLAB®.

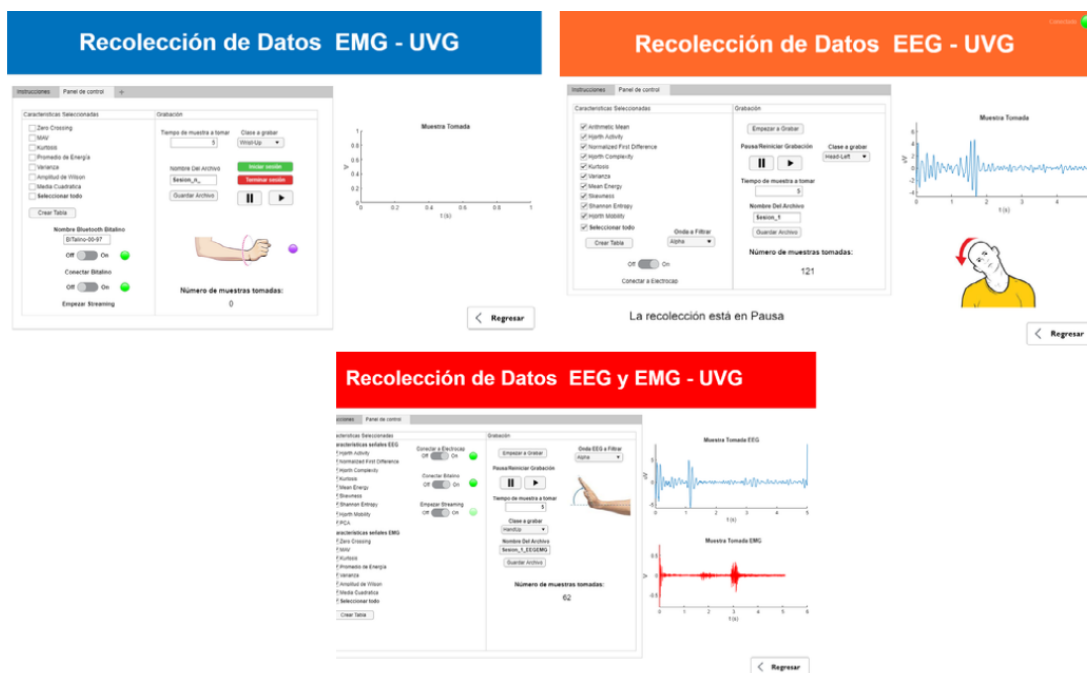


**Figura 1.** Estructura de funcionamiento de las interfaces recolectoras y clasificadoras.

## Etapas de procesamiento, análisis y recolección de señales.

### Interfaces de recolección de señales

El objetivo de esta etapa era la integración de todos estos procesos para poder obtener una herramienta de recolección de datos. Esta etapa varía en las 3 interfaces recolectoras creadas, para las señales EMG, se utilizó el dispositivo *BITalino (r)evolution Board* para la adquisición de la señal como lo hizo Girón (2020). Para las señales EEG se utilizó el dispositivo *Electro Cap* con la *Cyton Board* como lo hizo López (2020). Para la interfaz recolectora donde se capturan ambas señales al mismo tiempo, se utilizaron los dos dispositivos antes mencionados para las señales respectivamente mencionadas. Las interfaces creadas con el *App Designer* de MATLAB, permitieron el análisis y recolección tanto en tiempo real como análisis posteriores, esto gracias a que las interfaces creadas permiten guardar la data por sesiones, clases y lo guardan como vector de características (con las características que se deseen seleccionar) o la señal guardada en bruto, sin procesar.




**Figura 2.** Interfaces recolectoras de señales EMG, EEG y EEG-EMG.

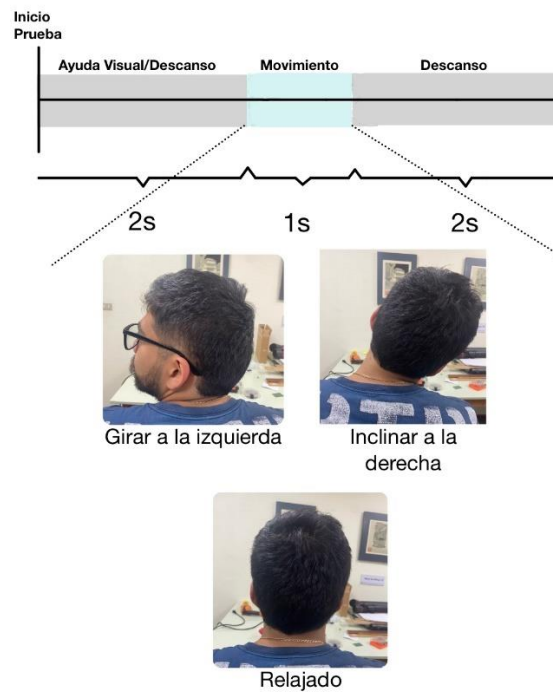
### Paradigmas Experimentales

Al tener las interfaces funcionando de forma adecuada, se procedió a determinar los paradigmas experimentales para realizar las pruebas con las interfaces clasificadoras. Se presentan 4 paradigmas distintos. Uno para la interfaz clasificadora de señales EMG, otro para la interfaz clasificadora de señales

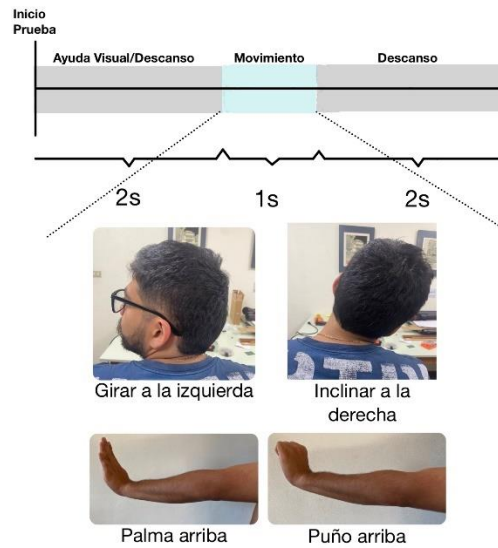
EEG y los últimos dos para la interfaz clasificadora de señales combinadas, esto porque se utilizaron dos enfoques distintos al momento de clasificar las señales EEG-EMG.



**Figura 3.** Paradigma experimental utilizado para interfaz clasificadora de señales EMG.



**Figura 4.** Paradigma experimental utilizado para interfaz clasificadora de señales EEG.



**Figura 5.** Paradigma experimental utilizado para interfaz clasificadora de señales EEG-EMG.

Todos los paradigmas experimentales coinciden en tener una ventana de tiempo para la captura de cada señal de 5 segundos. En los primeros dos segundos, para cada paradigma se estableció que el individuo descansaría 2 segundos y obtendría una ayuda visual de la clase a grabar. Después de esos 2 segundos el individuo tiene que realizar, el movimiento/gesto/clase establecido por 1 segundo. Luego el sujeto descansa otros 2 segundos antes de empezar a capturar otra muestra. La figura 1 muestra los movimientos/gesto/clase que se recolectaron para las pruebas con los entrenamientos para señales EMG, así como los entrenamientos realizados para el primer enfoque de combinación de señales EEG-EMG, que es el de determinar el peso que tienen las señales EEG en las señales EMG cuando se clasifica. La figura 2 muestra los movimientos/gestos/clase que se recolectaron para las pruebas con los entrenamientos para señales EEG. Por último, la figura 5 muestra los movimientos/gesto/clase que se recolectaron para las pruebas con los entrenamientos para el segundo enfoque de la combinación de señales EEG-EMG, que es el de combinar gestos que no tienen correlación cuantitativa uno sobre el otro, en otras palabras, como si se tuviera dos clasificadores distintos.

## Interfaces Clasificadoras y Algoritmos de clasificación.

### *Data recolectada.*

Como se mencionaba en la sección anterior se realizaron 4 paradigmas experimentales. Para el primero, se recolectaron 479 muestras por cada uno de los movimientos/gestos/clases establecidos, en 4 sesiones distintas de recolección. Por cada prueba se obtuvo un vector de características de 7 dimensiones. Las

características seleccionadas fueron Cruces por cero (ZC), Valor absoluto medio (MAV), Curtosis (KUR), Varianza (VAR), Amplitud de Wilson (AW) y Media cuadrática (SMR).

Para el segundo se recolectaron 476 muestras por cada movimiento/gesto/clase establecido en 4 sesiones distintas de recolección. En este caso hubo dos tipos de vectores de características, uno de características en el dominio del tiempo y el otro vector está basado en el paquete de descomposición de wavelet, de los nodos (5 2), (5 3), (5 4), (5 5), (5 6) y (5 7) que representan las frecuencias de 8Hz a 32 Hz, este vector de características funciona de una buena manera en señales EEG ya que descompone las señales en varios niveles de tiempo-frecuencia según Dingyin y colaboradores (2011) . Las características seleccionadas en el dominio del tiempo fueron: HjorthActivity (HA), Primera Diferencia Normalizada (NFD), HjorthComplexity (HC), Curtosis (KUR), {Energía Media} (ME), Skewness (Sk), Entropía de Shannon (SE), HjorthMobility (HM) y Análisis del componente principal (PCA). El vector de características utilizado con la transformada de wavelet fue Media aritmética (AM), Entropía de Shannon (SE) y Desviación estándar (SD).

Para el tercero y cuarto paradigma experimentales, se utilizaron los mismos vectores de características, pero esta vez con muestras grabadas al mismo tiempo con los dispositivos bitalino y electro cap por cada una de las clases para ambos enfoques. Para el paradigma experimental de la figura 3 relacionado al primer enfoque de la combinación de señales EEG-EMG se recolectaron 438 muestras por cada movimiento/gesto/clase establecido en 2 sesiones distintas de recolección. Para el paradigma experimental de la figura 5 relacionado al segundo enfoque de la combinación de señales EEG-EMG se recolectaron 220 muestras por cada movimiento/gesto/clase establecido en 1 sesión.

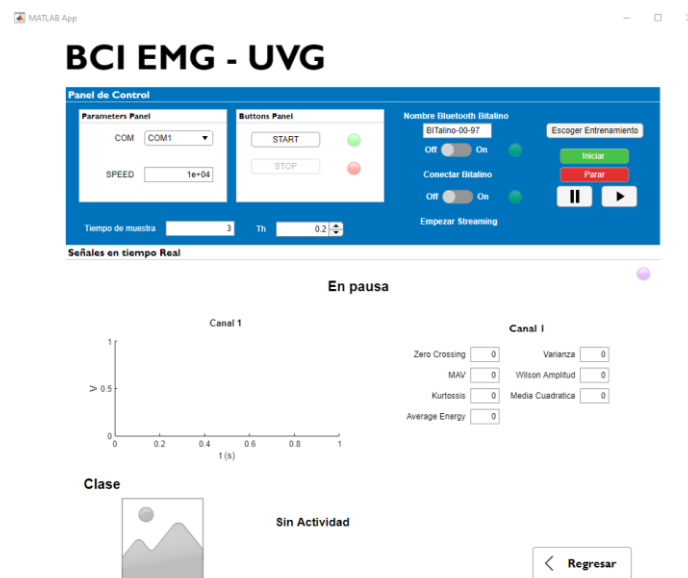
#### *Algoritmos de clasificación*

Para la clasificación de las bases de datos recolectadas, se decidió utilizar dos aplicaciones con las que cuenta el *software* MATLAB® siendo estas: *classification learner* MATLAB y *neuronal net fitting* MATLAB, además se utilizaron redes neuronales basadas en Python para tener otro punto de comparación más que no solo sea entre modelos, sino también entre los mismos modelos en diferentes lenguajes de programación. El *classification learner* MATLAB permite entrenar 6 modelos de clasificación en simultaneo y cuenta con variantes de los algoritmos de clasificación como máquina de soporte de vectores (SVM) algoritmos de árboles de decisión, análisis discriminante, clasificadores de regresión logística y clasificadores de vecino más cercano (KNN). El *neuronal net fitting* MATLAB permite realizar un entrenamiento con redes neuronales en este software.

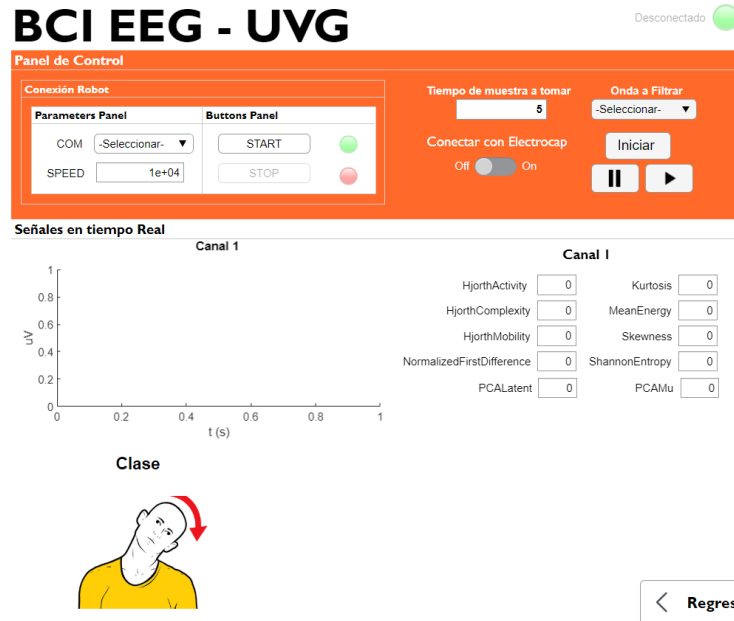


## Interfaces Clasificadoras

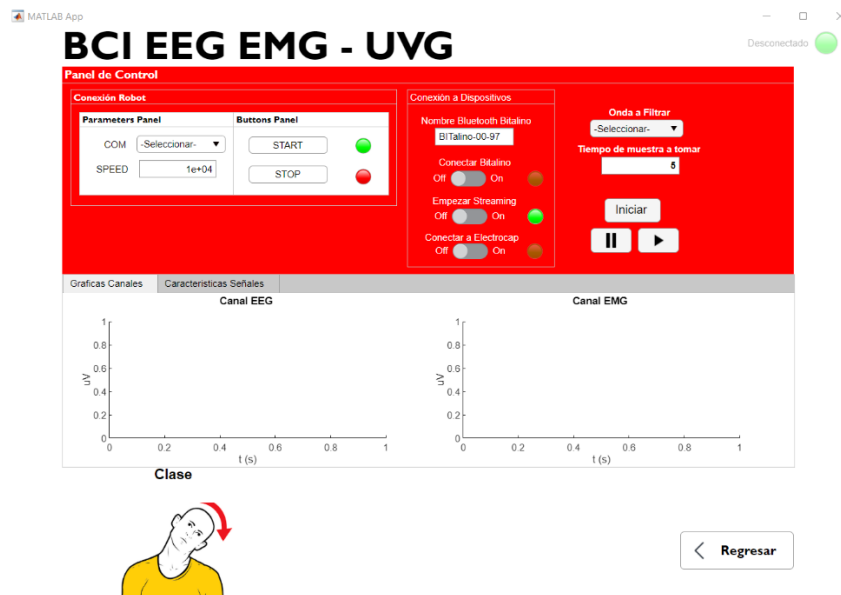
Para el desarrollo de las interfaces clasificadoras, se decidió utilizar de igual manera el software MATLAB® con la aplicación *App Designer*. Las interfaces permiten la conexión mediante bluetooth a los dispositivos de adquisición de las señales, se puede establecer la ventana de tiempo de la muestra a tomar y también permite la conexión con el robot R17 por medio de comunicación serial. Se puede escoger el entrenamiento para clasificar, media vez cuenta con el vector de características establecido en la interfaz, si no es así, se tiene que cambiar el código interno de la interfaz. La interfaz despliega las características de la señal y la clase que detecto el clasificador del entrenamiento seleccionado. Las interfaces solo clasificaran si el algoritmo de detección de actividad detecta algún tipo de actividad.



**Figura 6.** Interfaz clasificadora de señales EMG



**Figura 7.** Interfaz clasificadora de señales EEG



**Figura 8.** Interfaz clasificadora de señales EEG-EMG.

## Resultados y discusión

### Resultados Entrenamientos

Para el primer paradigma experimenta que se puede observar en la tabla 1, los entrenamientos al contrario de lo esperado, entre más data se le incluía menor eran los porcentajes de rendimiento de clasificación. Esto seguramente es porque la data recolectada en cada sesión es bastante variada, esto representa una muestra muy variada de las clases. Recordando que el objetivo del ML no es clasificar exactamente las muestras con las que se entrenó, sino tener un buen rendimiento de clasificación en una muestra bastante variada. Los resultados se consideran aceptables y el modelo que se escogió para probar con la interfaz clasificadora es el modelo de SVM grado 3 con un vector de características de 7 dimensiones. Esto porque presento un buen rendimiento en todos los entrenamientos. Otra cuestión para considerar es las RN en Python, que presentaron resultados muy superiores a los que presentan las RN en MATLAB. Esto es seguramente porque en Python se pueden manejar más parámetros y construir las redes neuronales de una forma más tangible.

**Tabla 1.** Resultados de entrenamientos con todas las muestras del paradigma 1.

Algoritmo	Vector de características	Clases	Rendimiento
SVM (3er grado)	ZC, MAV, KUR, AE, VAR, AW, SMR	Palma arriba, Puño arriba	<b>89.3%</b>
Árbol de decisión Fino	ZC, MAV, KUR, AE, VAR, AW, SMR	Palma arriba, Puño arriba	88.2%
Medium KNN	ZC, MAV, KUR, AE, VAR, AW, SMR	Palma arriba, Puño arriba	87.2%
Regresión logística	ZC, MAV, KUR, AE, VAR, AW, SMR	Palma arriba, Puño arriba	84.8%
Discriminante Linear	ZC, MAV, KUR, AE, VAR, AW, SMR	Palma arriba, Puño arriba	82.1%
SVM (3er grado)	AE, VAR, AW, SMR	Palma arriba, Puño arriba	86.1%
Árbol de decisión Fino	AE, VAR, AW, SMR	Palma arriba, Puño arriba	78.6%
Medium KNN	AE, VAR, AW, SMR	Palma arriba, Puño arriba	86.1%
Regresión logística	AE, VAR, AW, SMR	Palma arriba, Puño arriba	80.4%
Discriminante Linear	AE, VAR, AW, SMR	Palma arriba, Puño arriba	80.3%
RN (Python)	ZC, MAV, KUR, AE, VAR, AW, SMR	Palma arriba, Puño arriba	<b>99.2%</b>

RN (MATLAB)	ZC, MAV, KUR, AE, VAR, AW, SMR	Palma arriba, Puño arriba	87.2%
-------------	--------------------------------	------------------------------	-------

Para el segundo paradigma experimental al igual que en el primero entre más datos se agregaban a los modelos, el rendimiento baja como se pueden mostrar en los resultados mostrados en la tabla 2. Esto pasó con casi todos los modelos y utilizando 2 y 3 clases. A excepción del modelo donde se usó el *Wavelet packet decomposition* para entrenar, que presento un mejor rendimiento en la última sesión de entrenamiento. Esto da pauta a poder escoger entre dos de los mejores entrenamientos, siendo estos SVM de segundo grado con el vector de características de 10 dimensiones y utilizando el SVM de tercer grado usando *Wavelet packet decomposition*. Para escoger entre ambos entrenamientos, se tuvo que determinar si el rendimiento de clasificación es lo suficientemente bueno como para aceptar ese tiempo extra que generaba usar *Wavelet packet decomposition*, ya que su procesamiento es caro computacionalmente como para implementarse en tiempo real.

**Tabla 2.** Resultados de entrenamientos con todas las muestras del paradigma 2.

Algoritmo	Vector de características	Clases	Rendimiento
SVM (2do grado)	HA, NFD, HC, KUR, ME, SK, SE, HM, PCA	Inclinar a la derecha, Girar a la izquierda	<b>81.1%</b>
Árbol de decisión Fino	HA, NFD, HC, KUR, ME, SK, SE, HM, PCA	Inclinar a la derecha, Girar a la izquierda	82.2%
Medium KNN	HA, NFD, HC, KUR, ME, SK, SE, HM, PCA	Inclinar a la derecha, Girar a la izquierda	80.6%
Regresión logística	HA, NFD, HC, KUR, ME, SK, SE, HM, PCA	Inclinar a la derecha, Girar a la izquierda	71.7%
Discriminante Linear	HA, NFD, HC, KUR, ME, SK, SE, HM, PCA	Inclinar a la derecha, Girar a la izquierda	72.3%
SVM (2do grado)	HA, NFD, HC, KUR, ME, SK, SE, HM, PCA	Inclinar a la derecha, Girar a la izquierda, Relajado	<b>86%</b>
Árbol de decisión Fino	HA, NFD, HC, KUR, ME, SK, SE, HM, PCA	Inclinar a la derecha, Girar a la izquierda, Relajado	84%
Medium KNN	HA, NFD, HC, KUR, ME, SK, SE, HM, PCA	Inclinar a la derecha, Girar a la izquierda, Relajado	84.1%
Discriminante Linear	HA, NFD, HC, KUR, ME, SK, SE, HM, PCA	Inclinar a la derecha, Girar a la izquierda, Relajado	74.5%

RN (Python)	HA, NFD, HC, KUR, ME, SK, SE, HM, PCA	Inclinar a la derecha, Girar a la izquierda	79%
RN (MATLAB)	HA, NFD, HC, KUR, ME, SK, SE, HM, PCA	Inclinar a la derecha, Girar a la izquierda	76.5%
SVM (3er grado)	Wavelet packet decomposition	Inclinar a la derecha, Girar a la izquierda	<b>89.4%</b>

Partiendo de los supuestos en los que se mencionaba que las señales EEG aportan un valor agregado a las señales EMG, dándole mejor rendimiento a los clasificadores entrenados utilizando ambas señales. Se puede deducir de los resultados de los entrenamientos que se pueden observar en la tabla 3 que en efecto cuando uno combina las señales EMG y EEG al tener una pequeña cantidad de datos o señales EMG no discriminantes, en si aportan un peso y mejoran el rendimiento de los clasificadores. Cuando el número de muestras aumentan, los vectores de características de las señales EEG dejan de mejorar el rendimiento de la clasificación de los entrenamientos. Incluso el rendimiento sin los vectores de características extraídos de las señales EEG el rendimiento de los clasificadores mejoran.

**Tabla 3.** Resultados de entrenamientos con todas las muestras del paradigma 3 segundo enfoque para la combinación de señales EEG-EMG.

Algoritmo	Vector de características	Clases	Rendimiento
SVM (3er grado)	<b>EEG:</b> HA, NFD, HC, KUR, ME, SK, SE, HM, PCA, <b>EMG:</b> ZC, MAV, KUR, AE, VAR, AW, SMR	Palma arriba, Puño arriba	<b>89.6%</b>
Árbol de decisión Fino	<b>EEG:</b> HA, NFD, HC, KUR, ME, SK, SE, HM, PCA, <b>EMG:</b> ZC, MAV, KUR, AE, VAR, AW, SMR	Palma arriba, Puño arriba	87.9%
Regresión logística	<b>EEG:</b> HA, NFD, HC, KUR, ME, SK, SE, HM, PCA, <b>EMG:</b> ZC, MAV, KUR, AE, VAR, AW, SMR	Palma arriba, Puño arriba	<b>92.4%</b>
SVM (3er grado)	<b>EMG:</b> ZC, MAV, KUR, AE, VAR, AW, SMR	Palma arriba, Puño arriba	<b>91.3%</b>

Árbol de decisión Fino	<b>EMG:</b> ZC, MAV, KUR, AE, VAR, AW, SMR	Palma arriba, Puño arriba	89.3%
Regresión logística	<b>EMG:</b> ZC, MAV, KUR, AE, VAR, AW, SMR	Palma arriba, Puño arriba	<b>92.4%</b>

En general se presentó un buen rendimiento para cada uno de los entrenamientos como se puede observar en la tabla4. Se confirma que la combinación de señales EEG y EMG se puede llevar a cabo, partiendo desde el hecho de tener 4 clases distintas donde 2 clases dependen directamente del sensor de señales EMG (bitalino) y las otras 2 clases dependen directamente del sensor de señales EEG (electro cap).

**Tabla 4.** Resultados de entrenamientos con todas las muestras del paradigma 4 primer enfoque para la combinación de señales EEG-EMG.

Algoritmo	Vector de características	Clases	Rendimiento
SVM (3er grado)	<b>EEG:</b> HA, NFD, HC, KUR, ME, SK, SE, HM, PCA <b>EMG:</b> ZC, MAV, KUR, AE, VAR, AW, SMR	Palma arriba, Puño arriba, Inclinar a la derecha, Girar a la izquierda	<b>89.5%</b>
Árbol de decisión Fino	<b>EEG:</b> HA, NFD, HC, KUR, ME, SK, SE, HM, PCA <b>EMG:</b> ZC, MAV, KUR, AE, VAR, AW, SMR	Palma arriba, Puño arriba, Inclinar a la derecha, Girar a la izquierda	86.6%
Medium KNN	<b>EEG:</b> HA, NFD, HC, KUR, ME, SK, SE, HM, PCA <b>EMG:</b> ZC, MAV, KUR, AE, VAR, AW, SMR	Palma arriba, Puño arriba, Inclinar a la derecha, Girar a la izquierda	87.1%

Discriminante Linear	<b>EEG:</b> HA, NFD, HC, KUR, ME, SK, SE, HM, PCA <b>EMG:</b> ZC, MAV, KUR, AE, VAR, AW, SMR	Palma arriba, Puño arriba, Inclinar a la derecha, Girar a la izquierda	84.9%
Bagged Trees	<b>EEG:</b> HA, NFD, HC, KUR, ME, SK, SE, HM, PCA <b>EMG:</b> ZC, MAV, KUR, AE, VAR, AW, SMR	Palma arriba, Puño arriba, Inclinar a la derecha, Girar a la izquierda	<b>90.5%</b>

## Conclusiones

Al incluir más datos a los entrenamientos, los porcentajes de rendimiento en la mayoría de los clasificadores, disminuye. Esto debido a que las muestras se vuelven más variadas, lo que quiere decir esto es que, al recolectar la data en sesiones diferentes, en condiciones diferentes, con estados de ánimos diferentes, incluso variando el sonido ambiente, simulando estar entre mucha gente, en el caso de las señales EEG, representa una muestra más variada de las clases, lo que permite una mejor clasificación. Se concluye esto porque siguen manteniendo buenos rendimientos de clasificación.

Las redes Neuronales desarrolladas en Python son más eficientes que las redes neuronales desarrolladas en MATLAB. Esto seguramente porque las redes neuronales desarrolladas en Python incluían un mayor manejo de parámetros, como el *learning rate*, la tolerancia y las funciones de activación entre capas ocultas.

Utilizar las señales EEG como vector de características auxiliar (como se planteó en el primer enfoque de combinación de señales EEG-EMG) para clasificar señales EMG demostró funcionar cuando se tiene una poca cantidad de muestras. Al aumentar las muestras, ese vector deja de aportar significativamente a los entrenamientos. Esto no implica que el caso sea el mismo para otros tipos de paradigma experimental. Combinar clases que dependan directamente de un sensor y del otro en un solo entrenamiento, resulto ser efectivo y funciona de forma óptima, esto permite aumentar el número de clases para un mayor control en sistemas robóticos.

## Agradecimiento

Se agradece al estudiante José David Pellecer, de la carrera de ingeniería mecatrónica por el apoyo, brindando un fácil acceso a la interfaz para conectarse al robot R17 y a todas las funciones necesarias para poder enviarle comandos.

## Bibliografía

- Camilo Ebensperger, Estuardo Méndez. (2018). *CARACTERIZACIÓN DEL PACIENTE CON AMPUTACIÓN*. Guatemala: Universidad de San Carlos De Guatemala.
- Dingyin, H., Wei, L., & Xi, C. (2011). Feature extraction of motor imagery EEG signals. *International Conference on Complex Medical Engineering* (pág. 4). Harbin, China: University of Science & Technology.
- Dulantha, T., Teramoto.Kenbu, Hayashi, Y., & Kiguchi.Kazuo. (2013). Towards Hybrid EEG-EMG-Based Control Approaches to beUsed in Bio-robotics Applications: Current Status, Challenges and Future Directions. *PALADYN Journal of Behavioral Robotics*, 147-154.
- Girón, M. (2020). *Interfaz Biomédica para el Control de Sistemas Robóticos Utilizando Señales EMG*. Guatemala: Universidad del Valle de Guatemala.
- López, O. (2020). *Análisis y Reconocimiento de Patrones de Señales*. Guatemala: Universidad del Valle de Guatemala.
- Ralda, R. R. (2020). *Interfaz Biomédica para el Control de Sistemas Robóticos Utilizando Señales EEG*. Guatemala: Universidad del Valle de Guatemala.
- Xiangxin, L., Oluwarotimi, S., Xu, Z., Hui, W., Fang, P., & Guanglin, L. (2017). A motion-classification strategy based on EMG-EEG signal combination for upperlimb amputees. *Journal of NeuroEngineering and Rehabilitation*, 13.